# 长期交互式 AI 记忆系统技术方案

初稿 *v0.1*　*2026* 年 *10* 月 *29* 日

本方案面向 D.I.V.E. 项目的个人技术方案评审，以当前恢复后的 main 工作区为实现基础。建议继续采用独立记忆服务：将历史对话整理为带来源、时间和对象信息的长期事实，经混合检索与本地重排后返回给宿主 Agent，由宿主完成回答。

当前主干可作为继续完善的基线。已有一组 20 题开发回归取得原始判分 19/20、正常交付 20/20；这些题目此前使用过，结果只能说明该样本的运行表现，尚不能证明架构泛化或正式验收通过。[9][10]

## 一 目标与项目范围

系统需支持跨会话积累、信息更新、精准检索、生成复用和记忆生命周期管理。交付范围包括可运行入口、架构与数据模型、写入和检索等流程、可复现评测记录及失败分析。[1，第 1 至 2 页、第 5 页]

| 手册要求 | 本方案的对应设计 |
| --- | --- |
| 记忆机制 | 工作窗口、结构化长期事实、可追溯的原文归档分别承担不同职责。 |
| 模型解耦 | 记忆 API 返回上下文；抽取、嵌入与回答模型通过独立接口和角色配置接入。 |
| 统一评测 | 正式目标按 LongMemEval Oracle 500 题组织；当前仅使用既有小样本记录作为开发证据。 |
| 工程交付 | 保留源码、配置、原始响应、用量与错误；关键流程可定位到输入、选中事实和最终提示。 |

### 设计取舍

记忆粒度由信息内容决定。一段对话可能同时包含多个人物、事件、限制、表格与助手建议，因此会拆成多条事实；库内事实数量与一次返回数量分开管理。原文归档用于恢复和显式查源，默认答题使用选中的事实。

本期以公开数据和可解释的独立实现为主，采用现成嵌入、重排与生成模型。生产级高可用和大规模集群不作为本初稿的交付目标。[1，第 5 至 6 页]

# 二 技术选型与参考关系

| 环节 | 选型及实际用法 | 理由与边界 |
| --- | --- | --- |
| 核心服务 | Python 自研模块；CLI、Web 和 HTTP API。 | 写入、存储、读取、生命周期和宿主回答分开。当前不是套用完整开源记忆框架。[9] |
| 存储 | Qdrant 保存记录、稠密向量和词项稀疏索引。 | 减少多套数据库之间的同步；实体和关系也作为记录保存，当前未引入 Neo4j。[3][9] |
| 嵌入 | 本地 BAAI/bge-m3，1024 维稠密向量。 | 支持多语言语义匹配；当前词项通道由自有代码生成，未直接采用 BGE-M3 的稀疏输出。[4] |
| 候选融合 | 语义向量＋词项检索，使用 RRF 式排名融合。 | 兼顾语义和名称匹配；密集通道还使用相似度权重，不能与标准 RRF 或 BM25 实现画等号。[3][9] |
| 重排 | 本地 bge-reranker-v2-m3，对问题与候选事实联合评分。 | 读取阶段无需再调用生成式选择模型；仍有本地推理与模型加载开销。[5] |
| 关系与时间 | 事实附带对象、事件、关系及发生和报告时间；有界关联扩展。 | 借鉴多路检索和显式时间表达；Graphiti 是设计参考，当前不依赖其运行时。[2][6] |
| 抽取与回答 | 模型按用途独立配置；历史回归中均使用配置标识 gpt-6-luna。 | 保留接口替换能力；模型别名不等于不可变模型快照，服务波动与拒绝仍需记录。[9][10] |
| 返回与集成 | 本地模板返回 context，完整 items 留给调用方。 | 参考 LlamaIndex 的元数据投影和 LangChain 的内容与工件分离；当前未接入这两个框架。[7][8] |

### 为何采用这组组合

生成模型主要用于写入时理解语义和最终回答；候选召回、融合、重排及排版使用可观测的独立组件。这样可以分别定位“漏存、未召回、未装入、未正确使用”，并单独统计费用和延迟。

上游项目提供的是机制与接口参考，其公开测试成绩不能直接视为本系统的效果。当前没有证据表明本方案已优于 Mem0、Graphiti 等开源系统。

# 三 记忆模型与状态管理

| 层次 | 保存内容 | 使用方式 |
| --- | --- | --- |
| 工作窗口 | 当前会话最近若干完整轮次，受条数和输入预算限制。 | 由宿主在当前交互中提供，帮助理解指代和尚未整理的近期内容。 |
| 长期事实 | 事实正文、结构化值、说话人类别、主体属性、事件与时间、状态及来源关联。 | 跨会话检索、重排和返回，是默认记忆读取的主体。 |
| 原文归档 | 持久化消息及成对的用户和助手轮次；保留来源编号与片段定位。 | 用于追溯、补抽和显式来源查询；默认事实召回不自动附上原文正文。 |

### 事实数据模型

Fact 的关键字段包括 text、kind、subject、attribute、value、event、recorded_at、status、confidence、semantics、relations，以及来源轮次关联。semantics 承载对象和事件身份、计划或完成状态、限定条件、数量类型及任务角色等。表格、列表、顺序步骤可以保存在结构化 value 中。[9]

事件发生时间与报告时间分别保存；用户事实与助手提供的信息分别标记。结构和来源能帮助解释记忆，但不能证明抽取语义完整，也不能保证模型最后使用正确。

### 写入流程

消息先持久化。会话关闭或达到整理触发条件后，抽取模型生成事实，自有字面结构处理补充列表和表格，再进行格式归一、逐条异常隔离、精确去重、关系索引和向量写入。合法事实可保留；整份响应无法解析、输出未完成或服务方拒绝仍可能使该批失败，需保留诊断和补抽入口。

### 更新与冲突流程

当前默认写入采用追加与精确去重：相同事实可关联新来源，不同文本保留为独立事实，避免过早合并不同事件。数据模型保留有效期和版本指向，旧的确认与版本链接接口仍存在；默认新增流程没有自动生成冲突确认项。因此，自动识别“更正同一状态”和“新增独立事件”尚属缺口，不能把字段存在写成机制已完成。

### 遗忘流程

会话整理结束或显式维护时，按重要性、时近度、访问次数和置信度计算保留分，对低价值或超容量条目逻辑归档；历史查询或候选不足时可检索归档。显式 forget 使目标退出检索，并处理共享来源的连带关系。归档和软遗忘不代表物理磁盘回收或备份擦除。[9]

# 四 主干记忆写入与答题流程

图 1 恢复后主干工作区的逻辑流程。箭头表示处理和查询关系，不表示耗时；图内节点附有本地源码快照依据。

打开可交互流程图

# 五 返回接口与 Agent 窗口

对外读取入口是 MemorySystem.recall 或 POST /memsys/recall。记忆服务返回可用上下文，最终生成由宿主 Agent 决定。当前代理只注入 rec.context；示例适配器也可以使用 memory 和 rules 分开排版。[9]

| 返回字段 | 作用 | 是否装入模型提示 |
| --- | --- | --- |
| context | 包含当前日期、选中记忆正文与使用规则的字符串。 | 标准集成使用此字段一次。 |
| memory 与 rules | 正文与规则的独立形式，便于宿主定制排版。 | 属于 context 的组成内容，选择一种形式装入。 |
| items | 完整结构化条目，包括正文、值、身份、时间、来源和关系等。 | 供调用方处理或展示；整份 JSON 无需重复注入。 |
| trace 与 coverage | 候选、选中条目、运行阶段、覆盖范围与诊断信息。 | 用于定位过程问题；必要的不完整性提示已体现在上下文中。 |

## 接入示意

```
rec = memory.recall(user_id, question, at)
messages = host_messages_with_memory(rec.context)
answer = host_model.chat(messages)
```

host_messages_with_memory 是接入伪代码，表示由宿主把上下文装入一次；它不是当前仓库新增的函数。原文需要时，通过 /memsys/sources 使用来源轮次编号显式读取。

## 窗口占用与配置口径

历史主干 20 题的完整答题输入平均为 9,306 token，最大 25,344 token，包含宿主系统提示、问题与记忆；它不能当作记忆本身的精确 token 数。记忆正文平均 34,491 UTF-8 字节，完整 context 平均约 40,419 字节。字节数与模型 token 数分别报告。[10]

该回归配置使用 utf8 预算模式：记忆初始预算 65,536 字节，完整答题输入预算 131,072 字节，近期窗口最多 12 个完整轮次且受 24,000 字节约束。回答初始输出上限 8,192 token，抽取初始输出 65,536 token，二者另有有界扩容上限。配置名含 tokens 的输入预算字段在此模式下实际单位为字节。

实际 Agent 还会携带工具结果、系统指令和其他对话，适配时应按该宿主的 tokenizer 与剩余窗口核算。当前没有依据给出任意 Agent 的固定占用百分比。返回层先采用已验证的主干形式，后续仅对重复字段做可逆排版优化，并在真实调用中确认含义保留和输出行为。

当前普通最多 30 条，全量请求最多 60 条，宿主显式覆盖补取最多 128 条；均受预算限制，可配置且不要求填满。这些只是工程上限，完整性只针对已存事实，尚未证明是通用最优 K。默认读取后直接由宿主生成回答，没有回答后的审计关卡。[9]

# 六 已有实测与效果边界

以下是相同 20 道原题在不同时间的真实重新写入和回答记录，历史与原题保持一致，答案全部固定后才评分。它们均为已暴露的 Oracle 开发回归；主干数据来自历史运行，本次恢复后未新跑评测。[10][11][12]

| 指标 | 原主干 | Top 20 实验 | 返回层实验 |
| --- | --- | --- | --- |
| 原始判分 | 19/20 | 18/20 | 16/20 |
| 正常交付 | 20/20 | 20/20 | 19/20 |
| 回答输入 token | 186,117 | 90,442 | 163,643 |
| 成功生产 LLM 调用 | 53 | 53 | 51 |
| 新增生成式选择调用 | 0 | 0 | 0 |

返回层实验有一题在写入时遭服务方拒绝，未进入答题，因此不能把该轮全部输入和成功调用数减少视为节省。仅比较共同交付 19 题时，回答输入减少 4.38%，输出反而增加 21.75%；固定同一批事实的排版对照中，正文只缩小 0.81%，正文加规则缩小 5.22%。

## 当前能确认的效果

主干可贯通写入、事实检索和宿主回答，在该 20 题中全部正常交付；事实已存 1,137 条，最终装入 759 条，平均每题 37.95 条，普通与全量题的上限不同。默认答题原文摘录为 0。上述数量不能当作语义召回率、命中精度或事实实际使用率。

完整正常路径的 53 次生产生成调用由 33 次会话抽取和 20 次回答构成，开发评分另计 20 次。本地 embedding 和 BGE 推理不计入云端生成调用数，但会占用本地算力与时间。

## 主要限制与失败模式

抽取可能遗漏目标、身份、细节或表格关系；检索和选择可能遗漏完整计数所需事实；生成阶段可能拿错事件、时间或角色，也可能没有把已召回的目标用于建议。保存、召回和装入成功都不是最终回答正确的充分条件。

Top 20 实验的回答输入减少 51.41%，但原始判分下降，且写入和排序也有改动，不能据此推断仅缩小 K 的因果效果。返回层实验同样未证明质量保持。因此，当前保留主干，两个实验均作为研究记录。

主干平均读取加回答 50.24 秒，其中远端回答 36.44 秒、本地 BGE 约 11.76 秒。后续实验远端请求显著变快，但缺少首 token、服务排队和分段网络计时，不能全部归因于架构。主干有 6 次传输重试；开发评分与回答使用相同配置模型家族，仍有评分一致性局限。

# 七 预算估算与后续完善

手册要求方案阶段估算正式 500 题答题和官方评判成本。[1，第 2 页] 当前记录缺少有效单价，因此先给用量预算；以原主干 20 题乘 25 作为数量级占位。该样本题型配比、历史长度与正式全量未必一致，下表不是 500 题实测或准确费用预测。

| 用途 | 20 题调用 | 20 题输入与输出 token | 500 题等比占位 |
| --- | --- | --- | --- |
| 会话抽取 | 33 | 246,077 / 294,342 | 825 次<br>6.152M / 7.359M |
| 宿主回答 | 20 | 186,117 / 2,850 | 500 次<br>4.653M / 0.071M |
| 开发评分 | 20 | 3,755 / 477 | 500 次<br>0.094M / 0.012M |

生产部分等比约 10.805M 输入与 7.430M 输出 token，共 1,325 次成功生成调用；若再按题评分，共约 1,825 次。正式评判模型以项目组公布配置为准，开发评分的 token 仅作占位，须按正式提示和模型重新核算。

费用按各用途的百万输入和输出 token 分别乘以相应单价，再加入重试、缓存差异及本地嵌入、重排、存储资源成本。单价未配置时保留“未知”，不把日志中的零解释为免费。主干该轮完整串行运行约 80.7 分钟，等比为 33.6 小时，仅作调度容量参考。

## 下一步按问题层次完善

第一步，补足通用语义契约。围绕用户和助手归属、独立事件、同一状态更正、数量及单位、计划和完成、持续目标以及结构化表格编写自建场景；先固定预期，再实现。避免根据已知评测答案增设规则。

第二步，优先处理写入冗余与更新语义。该轮抽取输出占生产输出约 99.04%；在现有抽取调用内减少重复结构、保留独立事实，并为显式更正建立可追溯更新设计。自动裁决的错误成本需要独立验证，不立即新增逐条模型调用。

第三步，完善集成与故障交付。继续只向模型提供一次 context，保留完整条目在服务侧；明确来源未处理完整时的产品行为与评测失败统计。语义诊断保留为观察信息，避免重新成为答案交付硬门槛。

第四步，固定代码和配置后做真实调用验证，同时报告准确率、交付率、分题型、输入输出、重试及本地和远端延迟。已暴露 20 题继续标为开发回归。正式 500 题、其他数据集和消融实验另行安排，本次只完成方案与预算。

# 八 参考来源与复现依据

外部资料于 2026 年 10 月 29 日核对。下列条目区分项目要求、实际依赖、设计参考和本地实测，便于后续修订与答辩说明。

### [1] D.I.V.E. 学生手册 v1.6

项目要求。第 2 页交付与预算，第 5 页技术范围，第 6 页 Oracle 方法，第 9 页参考与诚信边界。

### [2] LongMemEval 论文与官方实现

三阶段记忆设计、时间范围与统一评测参考。数据和官方评测入口见 LongMemEval 仓库。

### [3] Qdrant Hybrid Queries

实际存储技术的官方说明；混合检索与 RRF 机制参考。当前融合由本仓库执行。

### [4] BAAI bge m3 模型卡

实际嵌入模型依据。多语言、1024 维与长文本能力；当前只使用其稠密嵌入通道。

### [5] BAAI bge reranker v2 m3 模型卡

实际重排模型依据。输入问题与候选内容，输出相关度。

### [6] Graphiti SearchConfig 源码

设计参考。组合语义、关键词、关系遍历与重排；当前未采用 Graphiti 运行时。

### [7] LlamaIndex BaseNode 源码

返回层设计参考。区分送入嵌入与生成模型的元数据。当前未引入该框架。

### [8] LangChain retriever tool 源码

返回层设计参考。本地模板组织正文，可分别返回内容和完整文档工件。

### [9] 恢复后主干的源码快照

实现依据。core、write、read、update、store、lifecycle、schema、serve 及 webchat 共同核对。main 包含原有未提交改动，图中引用独立的本地快照，不冒充远端已提交版本。

### [10] 原主干 20 题回归记录

实测依据。原始 19/20，20 题交付，源码与本次恢复结果逐字节匹配。模型、用量和冻结配置保存在同目录。

### [11] Top 20 实验回归记录

保留的实验记录。原始 18/20，20 题交付；不作为当前默认实现。

### [12] 返回层实验回归记录

保留的实验记录。原始 16/20，19 题交付；错误、原始评分及共同交付子集的口径均保留。

### LongMemEval 官方数据与评测说明