D.I.V.E. × 川大 · 学生手册

长期交互式 AI 记忆系统 · Long-term AI Interactive Memory System

*赛诺菲（Sanofi）× 四川大学 · 2026 年秋季期 · **学生版 v1.6** · 2026-09-21*

> 本手册为 2026 年秋季期 D.I.V.E. 参与学生的执行与参考文件。第一、二章概述项目安排与课题要求；附录载明技术范围、LongMemEval 评测方法与评分标准。
> 本期采用个人赛计分：**40 / 20 / 15 / 15 / 10**（Benchmark · 代码质量 · 汇报答辩 · 团队协作与成长 · 潜力 JDI）。

一、项目说明

1.1 项目定位

D.I.V.E.（Digital · Innovation · Visionary · Empowerment）为赛诺菲与四川大学联合开展的**校企协同工程实践**。项目自 **2026 年 9 月 18 日**开幕式启动，交付截止 **12 月底（暂定）**。学生在企业 mentor 带教下，**独立**完成长期交互式 AI 记忆系统的设计、实现、评测与答辩。

项目形式为**真实工程交付**：含代码实现、文档、统一基准评测（LongMemEval Oracle，500 题）及结项答辩，非课程式旁听。

1.2 课题概述

大语言模型在长期、跨会话交互中普遍存在遗忘、事实不一致及信息更新识别不足等问题。仅依赖扩大上下文窗口无法从根本上解决上述问题，且长上下文下的细节检索能力会显著衰减。

本期课题要求：设计并实现**与底层 LLM 解耦**的记忆系统（Memory System），覆盖信息抽取、组织、更新、检索与复用，并以 **LongMemEval Oracle** 统一基准进行可复现评估。

1.3 能力要求

能力	英文	要求说明
积累	Accumulate	识别并写入需长期保留的信息，避免无差别存储原始对话
更新	Update	在信息变化或冲突时正确更新，保持当前有效事实清晰、可追溯
检索	Retrieve	回答时精准召回相关记忆，兼顾准确率与检索效率
复用	Reuse	将记忆有效融入生成过程，维持长程事实一致性
遗忘	Forget	建立时效、优先级或容量策略，控制记忆库规模与质量

1.4 个人赛与分组

- 15 名学生分 3 组，每组 5 人；**分组仅用于双周辅导、答疑与活动**。
- 每位学生独立确定实现路径，独立维护代码仓库与 Oracle 评测输出，独立答辩并计**个人总分**。
- 组内可开展技术讨论与互助；**不设团队总分**，不设组长，不要求团队统一交付物。

1.5 交付物

#	交付物	要求摘要
1	**可运行代码**	完整记忆模块与交互入口（CLI / Web / API 均可）；README 支持复现
2	**架构设计文档**	架构图、记忆数据模型、写入/更新/检索/遗忘流程、选型理由与已知局限
3	**Oracle JSONL**	全量 **500 题**：每行 `question_id` + `hypothesis`，供项目组统一复跑
4	**评估报告**	评测配置、Overall Accuracy、分题型结果、token/费用/耗时、失败模式分析
5	**答辩材料**	个人演示与问答（格式与时长以结项通知为准）

1.6 资源与合规

1. **算力与模型**：由学生自行准备；赛诺菲不提供模型、API 额度或算力。技术方案阶段须估算 **500 题答题及官方评判** 成本。
2. **数据合规**：全程仅使用公开数据，不涉及患者、企业敏感或个人隐私数据。
3. **模型训练**：不要求从零预训练或微调大语言模型；评价重点为记忆机制与工程质量。
4. **成果发布**：鼓励以开源或公开展示方式沉淀成果；**发布形式、署名及赛诺菲品牌使用须符合校企规范**，结项前由项目组确认。

二、项目执行安排

2.1 阶段划分

阶段	建议时间	主要工作	阶段产出
Phase 1 · Understand & Design	**9/18 — 11 月上旬**	研读 LongMemEval；确定个人架构与数据模型；小规模验证	**个人**技术方案（**11 月上旬**提交）；环境与依赖说明
Phase 2 · Build & Iterate	**10/10 — 11/30**	实现 ingest → 记忆核心 → 答题流水线；随双周辅导迭代	可运行模块、测试与日志；README 初版
Phase 3 · Benchmark & Optimize	**11 月下旬 — 12 月上旬**	全量 500 题评测；分题型分析与优化	JSONL（可迭代至终版）；评估报告草稿
Phase 4 · Deliver & Defend	**12 月中旬 — 12 月底（暂定）**	文档与代码收口；答辩演练；材料归档	终版交付物；**个人**答辩；Code freeze（以通知为准）

10/1–10/7 国庆假期不安排辅导。第 1 次双周辅导建议 **10/8–10/10**，此后约每两周一次，至 12 月中旬共 **6 次**。

2.2 里程碑

时间	事项
9/18	Launch / 开幕式（成都 Hub Office）：课题说明、分组、导师见面
10/8 起	双周辅导（约 6 次，线上，单次约 90 分钟）
11 月上旬	提交**个人**技术方案（具体截止日以项目组通知为准）
11 月	模拟面试工坊（**不计入总分**）
12 月	成都中心开放日 · **个人**结项答辩
答辩前约 3 个工作日	Code freeze，材料提交完毕
12 月底（暂定）	最终归档截止

2.3 双周辅导

单次结构：进度回顾（**每位学生须发言**）→ 技术深潜 → 行业/职业主题 → 下阶段目标（明确责任人与截止时间）。

出席及进度发言将记入辅导记录，用于「团队协作与成长」维度中的 **参与度（6 分）** 及结业认定（详见附录 E）。

2.4 导师机制

每组 **5 名学生、3 名 mentor**（技术、职业/文化、过程记录等分工于 Launch 后确认）。辅导采用**引导式**方式：不提供代写或标准答案替代；学生应携带具体问题、已验证方案及实验结果参与讨论。

2.5 沟通机制

场景	渠道
日常技术讨论	本组协作群（学生 + mentor）
全体通知	项目大群 / 邮件（Phoebe 发出）
流程、权益、成绩	Phoebe Cai（P&C）
课题与评测	tech mentor；必要时由项目组技术负责人协调

学生以校外参与者身份协作，使用 GitHub、邮件、会议链接等**公开工具**，无需赛诺菲内部账号。

2.6 学生权益与结果应用

项	内容
企业带教	赛诺菲工程师辅导与技术评审
量化评测	Oracle 统一复跑后的 Benchmark 得分
职业发展	11 月模拟面试工坊
项目证书	达到结业标准者
奖学金	Next Gen 等助学支持，**须符合校方与基金会资格要求**；名额与金额以通知为准
实习推荐	有限 Digital / GTMC 机会，**综合岗位匹配与项目表现**

个人总分将作为奖学金及实习推荐的重要评估依据之一。 最终结果还将综合考虑**项目资格要求**、**项目期间表现**及校企相关规定；**具体规则以项目组最终通知为准。**

身份说明：本项目不属于实习，无补贴或劳务费，不认定学分。成果用于竞赛、课程或毕业论文由学生与校方自行安排。

2.7 常见问题

问题	说明
缺少大模型项目经验	选拔侧重学习能力与投入；项目周期内可逐步建立能力
算力资源有限	建议中小规模开源模型及校方资源；方案阶段须完成成本评估
使用 AI 编程工具	允许合理使用；须保证可解释性，答辩将核验设计与实现
成绩异议	对 Benchmark、代码、答辩或记录表有异议，可在规定期限内书面申诉；细则以结项通知为准

附录 A · 课题背景与目标

A.1 研究背景

LongMemEval 等研究表明：即使在 Oracle 证据可见时模型表现较好，当必须从极长交互史中自行定位信息时，准确率会显著下降；带记忆的商用助手在长程场景下亦可能表现不佳。因此需要**可设计**、**可度量**的记忆模块，而非单纯依赖上下文窗口扩展。

A.2 评估目标

除实现可运行系统外，学生须建立**可复现的评估流程**，以 **Overall Accuracy** 及分题型分析说明记忆机制效果，而非仅依赖个别演示案例。

附录 B · 范围与技术要求

B.1 记忆机制（必做）

- **写入**：界定进入记忆的信息类型、触发时机与粒度。
- **结构与分层**：建议区分情景记忆（Episodic）、长期/语义记忆（Semantic）、工作记忆（Working）。
- **更新与冲突**：时间优先、置信度、显式确认等策略；历史版本保留方式。
- **遗忘与生命周期**：基于时效、访问频率、重要性或容量上限的策略。

B.2 存储与检索（必做）

- 存储：向量库、关系库、图结构或混合方案，**须说明选型理由**。
- 检索：语义 / 关键词 / 混合检索；可采用 Rerank、Query Rewriting、时间过滤等。
- **效率**：在评估报告中给出检索延迟或规模变化数据。

B.3 交互与集成（必做）

- 可运行的多轮、**跨会话**交互入口。
- 记忆模块与 LLM **解耦**：更换底层模型时不应重写整套记忆逻辑。

B.4 明确不在范围

- 从零预训练 / 微调 LLM（非本期重点）。
- 生产级高可用、大规模集群部署。
- 任何非公开、涉敏数据。

B.5 工程规范

- 代码托管于**公开仓库**（如 GitHub），保留**真实、完整**的 commit 历史。
- README：依赖、配置、一键复现步骤。
- 写入 / 更新 / 检索 / 遗忘模块边界清晰，关键路径具备基本测试。
- 日志或调试输出：可追踪单次回答所依赖的记忆检索过程。

B.6 可选方向（非强制）

记忆可视化、多用户隔离、记忆压缩与摘要、主动记忆、消融实验等；实现质量体现在**代码质量与创新性**评价中，不替代必做项。

附录 C · LongMemEval Oracle 评测

C.1 数据与流程

- 数据文件：**`longmemeval_oracle.json`**，**500 题**（Oracle 档；**不含** S/M 档与记忆损失实验）。
- 字段：`haystack_sessions`（证据会话）、`question` / `question_date`、`answer`。
- 流水线：**按时间 ingest 历史 → 回答 question → 输出 `hypothesis`**。
- 提交：JSONL，每行 `{"question_id": "...", "hypothesis": "..."}`，**500 题全覆盖**。

C.2 评测示例

证据会话中用户陈述：**「几个月前我独自在日本旅行了两周」**。
后续问题：*How long was I in Japan for?*
参考答案：**two weeks**（“2 weeks”等等价表述通常判为正确）。

若记忆模块未将上述事实写入**可检索**记忆，系统将难以答对。500 题对应不同 haystack，须实现**通用**流水线，**禁止**针对单题硬编码。

C.3 Benchmark 计分（40 分）

- 主指标：**Overall Accuracy**（官方脚本 `evaluate_qa.py` + 项目组公布的 **LLM 评判模型**，默认与论文一致常为 GPT-4o）。
- **Benchmark 得分 = Overall Accuracy × 40**（项目组以**同一 ref、同一评判模型**统一复跑，不以自报分为准）。
- 建议写入报告、**不计入 40 分换算**的指标：分 `question_type` 准确率、30 道拒答题（`_abs`）准确率、Task-averaged Accuracy 等。
- 须披露：答题模型、评判模型、参数、数据版本、全量 500 题的 token/费用/耗时。

Oracle 档说明：历史已剪至证据会话，考察**写入、更新、组织与调用**；将 haystack 全量拼入上下文以绕过记忆设计，属于**投机实现**（见附录 F）。

附录 D · 交付物详细说明

交付物	具体要求
可运行代码	记忆模块 + 交互入口；README 可复现
架构文档	架构图、数据模型、四类流程、选型与局限
JSONL	500 题 `question_id` + `hypothesis`
评估报告	配置、Overall Accuracy、分题型、成本、失败模式
答辩	**个人**展示 + 问答

发布与署名：鼓励以开源或公开展示方式沉淀成果。**发布形式、署名及赛诺菲品牌使用须符合校企规范**，结项前由项目组确认。在遵守学术诚信前提下，成果可用于竞赛、课程或论文（非强制）。

附录 E · 评分、主观分公平性与结业

E.1 个人总分构成（100 分）

板块	分值	说明
Benchmark	40	客观分；统一复跑 Oracle JSONL
代码质量	20	2 名 mentor 评审个人仓库（至少 1 名非本组），取平均
汇报答辩	15	**个人**演示 + 问答
团队协作与成长	15	见 E.2
Hire for Potential · JDI	10	见 E.3

技术相关合计 **75 分**；过程与潜力合计 **25 分**。

E.2 团队协作与成长（15 分）

本维度为**个人分**，衡量学生在同组辅导中的投入与成长轨迹，非团队项目分摊。

维度	分值	评定方式
双周辅导参与度	6	**客观**：6 次辅导，出席且在进度回顾发言 = 1 分/次；出席未发言 = 0.5；请假/缺席 = 0
技术互助	5	组内答疑、共享技术笔记、同伴互评等
学习主动性	4	相对 11 月上旬方案评审后的成长幅度

关于 25 分主观分（协作 15 + 潜力 10）的公平性

- 评分前，项目组组织 mentor **跨组校准**，并对照**具体行为证据**打分。
- **该部分不以「表现活跃」或「发言次数多」为高分标准**，而重点关注**真实投入、成长变化、协作行为及承诺兑现**；每项主观分须附**具体事例**（不接受「表现良好」等空泛评语）。
- **参与度 6 分**依据记录表上的出席与进度发言记录；发言质量体现在「技术互助」「学习主动性」等维度，且须有事例支撑。

E.3 Hire for Potential · JDI（10 分）

JDI 为赛诺菲内部常用表述：

- **J — Judgement（判断力）**
- **D — Drive（自驱力 / 执行力）**
- **I — Influence（影响力 / 协作影响）**

由 career / culture mentor 评定，用于评估**长期培养潜力**（含实习推荐参考），与 Benchmark 分数相互独立。

维度	分值	观察锚点
主动性与执行力（JDI）	4	主动推进、快速试错、交付可验证成果
成长潜力（Stretch）	3	面对超纲问题时的学习与应对
职业成熟度	3	沟通、响应及时性、承诺兑现

E.4 代码质量观察面（20 分）

观察面	分值
机制真实性	**6**
架构合理性	5
工程质量	4
文档质量	3
理解深度	2

主观项采用 **1–5 分 + 一句说明**，再折算至上述分值。

E.5 汇报答辩（15 分）

项	分值
展示	6
问答	9

E.6 奖学金、实习与排名

- 项目组将形成**个人总分及排序**，作为结业认定与奖学金 / 实习推荐流程的参考依据之一。
- 学生可获知**个人成绩及相关反馈**；**奖学金、实习及排名结果的公布方式以项目组最终通知为准。**

E.7 结业建议

- 提交**个人**全部交付物；
- 个人总分 ⩾ 60；
- 双周辅导出席 ⩾ 4 / 6（且进度回顾环节按要求发言）。

附录 F · 诚信、投机实现与 AI 工具

F.1 投机实现（显著扣分或判 0 分）

1. 针对评测题或答案硬编码、特判、规则匹配
2. 全量历史拼入上下文，以超长窗口替代记忆机制
3. 依赖超大模型能力掩盖记忆模块缺失
4. 对测试集过拟合调参，缺乏通用设计
5. 套用开源记忆框架且无法说明机制与改造

允许参考论文与开源项目，但须**标注来源**并说明设计取舍。

F.2 严重违规

伪造 JSONL、抄袭他人仓库、代跑或代写 —— 取消成绩 / 结业资格。

F.3 AI 辅助工具

允许合理使用 AI 工具辅助学习与开发；须保证**成果原创**、**过程可追溯**，答辩时可说明设计与实现。

附录 G · 参考资源

- **LongMemEval**：arXiv:2410.10813 · GitHub · 评测脚本 `src/evaluation/evaluate_qa.py`
- **LongMemEval-V2**（可选对照，非必做）：GitHub
- 论文 **indexing / retrieval / reading** 三阶段及 key / value / query / reading strategy 可作为设计参照
- 生成式智能体记忆流、RAG 重排、知识图谱式记忆等 —— 须在理解原理基础上完成**独立设计**

联系人

事项	联系人
项目流程、权益、正式通知	Phoebe Cai（P&C）
课题技术、Oracle 复跑与评测	Arthas Zeng（Digital）
组内辅导与日常问题	所属 mentor
校方事务	学生中心 / 课题对接老师

学生手册 v1.6 · Oracle · 个人赛 · 40/20/15/15/10 · 若与项目组书面通知冲突，以通知为准。