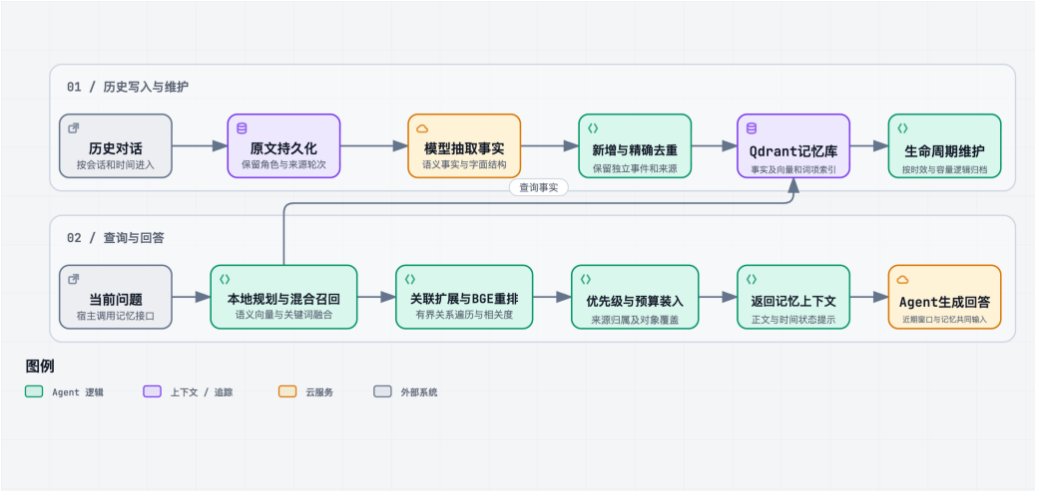
长期交互式 AI 记忆系统技术方案

初稿 v0.3　2026 年 10 月 30 日

一 整体流程



二 技术选型

基本能力包括跨会话持久保存、来源与时间关联、相关内容检索和宿主接入。具体数据库与模型可以替换，重排属于质量增强。选型依据是这些能力在当前处理链中的作用。

记忆抽取

长期交互必须区分谁说了什么、哪件事已经发生、哪件事仍是计划，以及信息属于哪个时间。缺少这些关系，系统容易把助手建议当成用户经历，或把不同事件合并。

（1）主方案在写入时抽取结构化事实，并关联原文、角色和时间，供后续检索、状态比较和聚合使用。原文持续保存，使遗漏的信息有重新处理的入口。时间与来源组织参考 LongMemEval 和 Graphiti。[1][5]

（2）原文分块可以省去语义抽取，但读取时需要由 Agent 重新理解事件与状态。本期保留结构化事实作为主方案，分块作为已实测的替代路线；两者的质量与用量在后面的同题表中对照。自动冲突识别仍需完善，已有时间字段不等于更新语义已经完整解决。

存储采用 Qdrant

跨会话复用需要持久存储，按用户隔离和按来源定位也是基本要求。Qdrant 可同时承载正文与元数据、稠密向量及词项稀疏索引，使两路检索和记录维护集中在同一服务。[2]

若已有 PostgreSQL，pgvector 配合全文检索可以沿用 SQL、事务和现有运维；关系路径成为主要查询需求时，图数据库更值得考虑。本期优先完成对话记忆检索，因此选择当前已接通的 Qdrant，避免同时维护多套检索存储。[8]

嵌入采用 BGE M3 并保留词项召回

用户会用不同说法询问同一件事，也会直接问人名或名称。语义向量用于匹配改写表达，词项通道补充原词匹配，两路按 RRF 名次融合；仅依赖其中一路会失去另一类匹配信号。[2]

BGE M3 支持多语言，模型输入上限 8192 token，为较长对话片段留出余量；实际输入仍按配置分窗。写入时建立向量，提问时编码查询。本期使用其稠密嵌入，词项索引由本地文本处理生成。作为替代的 multilingual e5 large 模型卡上限为 512 token，长片段需要更细分块，因此当前优先 BGE M3。[3][9]

数据模型与生命周期

原始轮次、事实及索引按命名空间和用户隔离。轮次保留角色、正文和记录时间。事实保存主体、属性、完整值、事件时间、置信度和来源轮次。稠密及词项索引关联事实编号，读取时核对可见版本及生命周期状态。

会话结束或达到整理阈值时创建持久任务。抽取结果经字段和来源校验后，事实、索引与处理水位一同发布。抽取失败时保留原文和原处理水位，供修正原因后重试。

更新时按主体、属性、完整值、时间与条件去重，冲突记录保留各自的来源。例如，用户六月搬到重庆，七月回忆四月住在成都，两条事实分别记录。读取时按事件时间区分当前与历史，写入顺序不自动覆盖旧值。

记忆遗忘按重要性、时近度和使用频率归档。主动遗忘会屏蔽受影响的事实及必要的原文范围，防止信息经召回、补抽或重建索引重新出现。审计数据保留，旧存储版本的物理清理由离线维护单独执行。

三 候选重排与 Agent 接入

在初步召回后进行本地重排

需要控制相关性和重复内容，才能把有限的上下文位置留给有用信息。bge reranker v2 m3 联合读取问题和候选，细化相关性排序；放在初召回之后，可将计算量限制在候选集内。[4]

本地重排无需增加远端生成调用。本期没有采用每题再调一次生成模型筛选的方案：同题实验中，筛选虽然缩短了回答输入，但回答加筛选的成功请求输入增加了 20.70%，原始得分也未超过主干。若延迟优先，可采用融合排序或更轻的重排器；

记忆上下文交给宿主 Agent

记忆需要能够跨模型复用。服务返回 context，由宿主把它与当前问题、近期对话一起交给回答模型；完整 items 与过程记录供程序处理。这样可以独立调整记忆组织与回答模型，并避免把相同正文以多种字段重复注入。

单个 Agent 可通过同进程库降低接入开销；多个宿主可使用独立 API。Python 便于复用当前嵌入、重排与评测工具，但不是记忆机制的必要条件。元数据选择参考 LlamaIndex，正文与完整文档分开返回参考 LangChain。[6][7]

跨会话复现可按项目 README 启动服务，在同一用户的第一个会话通过 /memsys/turns 写入自拟事实，调用 /memsys/end 并等待整理完成。第二个会话调用 /memsys/recall 核对返回的 context 和来源，再由宿主 Agent 生成回答。

开源项目的具体参考关系

来源	参考机制	对应环节
LongMemEval	历史索引 检索 阅读及时间推理	整体流程与评测
Graphiti	原始来源与事实关联 事实时间表达	记忆组织与状态
Qdrant 与 BGE	稠密和词项混合 检索后交叉编码重排	召回与排序
LlamaIndex	分别选择嵌入和生成所需元数据	正文与元数据组织
LangChain	正文和完整文档分别返回	宿主接入接口

重排、来源关联和结构化组织分别改善不同环节。最终效果还取决于写入是否保留必要信息，以及 Agent 是否正确使用已返回内容；单个组件的公开能力不能替代本系统的完整实测。

四 历次评测对照（小样本评测）

表 1 汇总 10 月 25 日至 29 日批次的 21 轮相关真实评测，包含主干、分支及定向错题复测。相同组号表示原题及顺序相同；不同组得分不直接作为版本优劣证据。日期沿用原记录批次名，所有结果均保留原始判分。

日期与版本	题组	原始判分	正常交付	生产生成成功响应	生产输入 / 输出千 token	平均答题输入 token	平均读答秒
10 月 25 日 列式抽取初版	A40	15/40	16/40	85	524.657 / 337.695	—	—
10 月 25 日 对象格式修复	A40	32/40	40/40	109	670.783 / 376.932	5,729	18.46
10 月 25 日 语义边界修复	A40	37/40	40/40	109	758.568 / 430.405	6,967	16.07
10 月 25 日 30 题对照版本	B30	25/30	30/30	79	528.300 / 296.266	6,860	18.36
10 月 26 日 硬校验版本	B30	21/30	23/30	76	567.160 / 416.159	—	—
10 月 26 日 七道流程失败题复测	定向 7	3/7	7/7	19	177.976 / 86.531	11,724	30.31
10 月 26 日 移除硬规则 三题复测	定向 3	3/3	3/3	8	75.265 / 31.859	12,086	29.70
10 月 26 日 校验仅作诊断	C20	18/20	20/20	52	398.642 / 204.803	8,525	17.74
10 月 26 日 记忆保真 两题复测	定向 2	2/2	2/2	4	24.312 / 10.747	6,142	23.95
10 月 26 日 记忆保真 完整复测	C20	18/20	19/20	51	422.611 / 259.886	—	—
10 月 27 日 抽取容错 两题复测	定向 2	2/2	2/2	7	83.215 / 55.880	20,473	30.12

日期与版本	题组	原始判分	正常交付	生产生成成功响应	生产输入 / 输出千 token	平均答题输入 token	平均读答秒
10 月 27 日 移除回答审计	C20	20/20	20/20	52	433.314 / 262.391	9,671	20.75
10 月 27 日 主干 另一组 20 题	D20	19/20	20/20	53	432.194 / 297.192	9,306	50.24
10 月 28 日 模型事实筛选分支	D20	18/20	20/20	68	474.740 / 294.577	4,174	38.57
10 月 28 日 紧凑写入 Top 10	D20	18/20	20/20	53	325.763 / 249.383	3,729	21.22
10 月 28 日 来源优先 Top 20	D20	18/20	20/20	53	360.213 / 250.054	4,522	19.37
10 月 28 日 Top 20 返回与表格改进	D20	17/20	20/20	53	365.777 / 260.001	4,970	19.17
10 月 29 日 返回层压缩分支	D20	16/20	19/20	51	397.443 / 293.980	—	—
10 月 29 日 主干 另一组 30 题	E30	24/30	30/30	78	628.740 / 375.059	9,425	21.55
10 月 29 日 原文分块初版	D20	15/20	20/20	20	113.941 / 3.646	5,697	19.09
10 月 29 日 原文分块 选择与返回改进	D20	18/20	20/20	20	119.313 / 3.943	5,966	17.07

口径 生产生成包含抽取、回答及成功返回的模型筛选，评分和本地嵌入、BGE 另计。失败请求的未知用量未补算。模型筛选分支有 20 次逻辑筛选请求，15 次成功返回，生产成功响应共 68 次。

含流程失败的批次不展示平均输入和读答耗时，避免把缺失工作当作效率收益。定向 2 题、3 题、7 题不能换算为完整评测成绩。表中版本名称可打开原始报告。

这些是已暴露的 LongMemEval Oracle 开发记录，部分题目重复使用，不能合并为独立样本总准确率。回答与评分采用同模型家族，已有评分一致性疑点；不同时间运行的远端耗时也不能全部归因于架构。

五 已有结论与参考来源

当前 Oracle500 自测

本次自测于 2026 年 11 月 6 日完成，采用仅事实索引和召回。原文留存用于溯源，原文向量及分块向量均为 0，生成式查询规划关闭。答题及独立会话判分均使用 qwen3.8-flash。

总体准确率为 87.40%（437/500），Task-averaged 为 89.73%，拒答子集为 24/30（80.00%）。499 题获得有效回答，1 题因答题接口 HTTP 400 无有效回答，按失败计入分母。分题型、用量及耗时见《Oracle500 最终评测报告》。项目组统一复评另计。

评测对当前方案的支持

主干已在 D20 组取得 19/20、在另一组 E30 取得 24/30，均完整交付；表现随题集变化。先前硬校验版本 B30 仅交付 23/30，说明审计字段不应成为答案交付的硬门槛。移除审计后的 C20 原始评分 20/20 仍含个性化使用不足的观察，分数通过不能代替内容复核。

D20 的模型筛选、Top 10、两版 Top 20 和返回层实验均未超过主干原始得分。减少返回内容有助于压缩输入，但来源优先、对象覆盖和事件时间仍需保留；返回层实验的一题流程失败发生在写入阶段，不能全部归因于排版。

原文分块从 15/20 改善到 18/20，仍低于主干 19/20；生产生成从 53 次降到 20 次，输入从 432,194 降到 119,313 token。该组记录支持省去抽取的用量收益，尚不足以证明质量替代。价格未配置，货币费用未作推算。

下一步应围绕抽取遗漏、候选选择以及已返回事实的使用分别改进，保留通用来源和时间表达，并以固定代码的真实调用检查质量、交付和用量。现有小样本尚不能证明完整长历史场景的泛化效果。

参考来源

[1] LongMemEval 官方数据与评测

[2] Qdrant 混合查询与 RRF

[3] BAAI BGE M3 模型说明

[4] BAAI bge reranker v2 m3 模型说明

[5] Graphiti 来源与时间关系

[6] LlamaIndex BaseNode 元数据组织

[7] LangChain retriever 工具返回形式

[8] pgvector 向量与全文检索

[9] multilingual e5 large 模型说明

外部选型资料核对日期为 2026 年 10 月 30 日。主方案流程依据保留的主干源码快照；评测数据与分支结果逐轮链接于表 1。